

Mini Project 2

SGAIM

RAG Pipeline

Bruno Rodrigues nº 52323
Mestrado em Engenharia Informática e Multimédia
ISEL - 2025/2026

Índice

Relatório Técnico — MP2 RAG Pipeline	3
1.1 Corpus e escolha	3
1.2 Pipeline e decisões.....	4
Ingestão	4
Chunking.....	4
Embedding	4
Vector Store.....	4
Retrieval	4
Generation	4
1.3 Benchmark — 10 perguntas	5
1.4 Comparação 1 — Chunking.....	6
Predict (antes de correr)	6
Measure	7
Explain	7
1.5 Failure analysis (Comparação 1).....	8

Relatório Técnico — MP2 RAG Pipeline

SGAIM 2025/2026

1.1 Corpus e escolha

O corpus escolhido é a **Atlântico Filmes, Lda.**, uma produtora de cinema fictícia portuguesa. O corpus é composto por 12 documentos em markdown que simulam a documentação interna da empresa: estatutos, catálogo de filmes, fichas de elenco, orçamentos, planeamento de rodagem, regulamento de prémios, histórico de prémios, procedimentos de contrato, calendário, código de conduta, instalações e história da produtora.

Porquê este corpus: - É completamente fictício — não existe na internet, logo não está nos pesos do LLM - Conseguimos verificar todas as respostas diretamente nos documentos. Tem 12 documentos com informação estruturada, tabelas e texto narrativo

Teste rápido (pergunta ao Claude sem corpus):

Pergunta	Claude sem corpus
Qual é a sede da Atlântico Filmes?	“Não encontro informações sobre essa empresa — pode dar mais contexto?”
Quem é a directora geral?	“Não tenho conseguido encontrar informações sobre a Atlântico Filmes.”
Em que ano foi fundada?	“Não tenho conseguido encontrar informações sobre uma empresa chamada Atlântico Filmes.”

O Claude sem corpus não conseguiu responder a nenhuma das três perguntas, confirmando que a Atlântico Filmes é completamente fictícia e não está nos pesos do modelo.

1.2 Pipeline e decisões

Ingestão

- **Decisão:** 12 ficheiros markdown lidos diretamente com open()
- **Alternativas:** PDF com pypdf — rejeitado por complexidade desnecessária
- **Porquê:** markdown é texto limpo, sem overhead de extração

Chunking

- **Decisão:** fixed size, 500 palavras, overlap de 50 palavras
- **Alternativas:** fixed 200; sentence-level
- **Porquê:** ponto de partida da aula 07; avaliado na Comparação 1

Embedding

- **Decisão:** nomic-embed-text via Ollama
- **Alternativas:** all-minilm, mxbai-embed-large
- **Porquê:** modelo local gratuito, recomendado na aula; 768 dimensões

Vector Store

- **Decisão:** ChromaDB com PersistentClient
- **Alternativas:** FAISS, Qdrant
- **Porquê:** simples de usar, persiste entre execuções, sem servidor externo

Retrieval

- **Decisão:** top-5 chunks por similaridade coseno
- **Alternativas:** top-3, top-10, reranking com cross-encoder
- **Porquê:** equilíbrio entre contexto suficiente e não encher o prompt

Generation

- **Decisão:** llama3.2:3b via Ollama, prompt com instrução de não inventar
- **Alternativas:** qwen2.5:7b, API OpenAI/Anthropic
- **Porquê:** modelo local, gratuito, suficiente para o corpus em português

1.3 Benchmark — 10 perguntas

#	Pergunta	Resposta esperada	Chunks relevantes?	Resposta do sistema	Correcta?
1	Qual é a sede da Atlântico Filmes?	Rua do Arsenal, n.º 78, Lisboa	Sim [1,2]	Rua do Arsenal, n.º 78, Lisboa	Sim
2	Quem é a directora geral actual da Atlântico Filmes?	Margarida Esteves (desde 2010)	Sim [4]	Margarida Esteves	Parcial
3	Em que ano foi fundada a Atlântico Filmes?	1998	Sim [1]	1998	Sim
4	Qual é o equipamento de câmara principal da produtora?	ARRI Alexa 35	Sim [2]	ARRI Alexa 35	Sim
5	Qual é a quota anual de um sócio efectivo?	1.200 €	Sim [1]	1.200 €	Sim
6	Qual foi o filme mais premiado da AF e quantos prémios ganhou?	Ferro e Sal (2023) — 6 prémios (nacionais + internacionais)	Parcial [3]	Ferro e Sal — 4 prémios no FCP	Parcial
7	Que realizadores trabalharam em mais de um filme na Atlântico Filmes?	Sofia Menezes (4), Pedro Alves Costa (3), Inês Carreira (2)	Não	“Não sei, essa informação não está nos documentos.”	Não
8	Qual é o prazo para reportar um acidente no set?	2 horas após o acidente	Sim [1]	2 horas	Sim
9	Qual é o salário da directora geral Margarida Esteves?	Não existe no corpus	Não	“Não sei, essa informação não está nos documentos.”	Sim

10	Quantos espectadores viu “Ferro e Sal” nas salas portuguesas?	Não existe no corpus	Não	“Não sei, essa informação não está nos documentos.”	Sim
----	---	----------------------	-----	---	-----

Notas:

- 2. Correta mas incompleta — omitiu “desde 2010”
- 6. Correto mas incompleto — recuperou catálogo (4 prémios FCP) em vez de histórico de prémios (6 no total); doc 07 não foi recuperado
- 7. Falha de retrieval — resposta existe em 03-elenco-atores.md mas não foi recuperado
- 9. Sistema admitiu ignorância correctamente — não alucinou
- 10. Sistema admitiu ignorância correctamente — não alucinou

1.4 Comparação 1 — Chunking

Variantes: fixed 500 palavras (baseline) vs fixed 200 palavras

Predict (antes de correr)

Com chunks de 200 palavras esperamos os seguintes efeitos:

- **Documentos curtos (~150 palavras):** sem diferença — já cabem num só chunk em ambos os cenários.
- **Documentos mais longos** (ex: 03-elenco-atores.md, 07-premios-conquistados.md, 04-orcamento-modelo.md): passam a ter 2–3 chunks separados por secção, o que deve melhorar o retrieval para perguntas específicas.
- **Pergunta 7 (realizadores):** esperamos melhoria — com chunks menores, a secção “Realizadores colaboradores” do 03-elenco-atores.md deve ficar num chunk próprio e ser recuperada.
- **Pergunta 6 (prémios totais):** esperamos melhoria parcial — o resumo estatístico do 07-premios-conquistados.md pode ficar num chunk separado.
- **Perguntas fáceis (1–5, 8):** sem alteração esperada — a informação é simples e estava a ser recuperada corretamente.
- **Risco:** com mais chunks no total, pode haver mais ruído — chunks irrelevantes com scores parecidos podem “roubar” posições ao chunk certo.

Measure

#	Pergunta	Chunks rel.? (500)	Correcta? (500)	Chunks rel.? (200)	Correcta? (200)
1	Sede da AF	Sim	Sim	Sim	Sim
2	Directora geral	Sim	Parcial	Sim	Parcial
3	Ano de fundação	Sim	Sim	Sim	Sim
4	Câmara principal	Sim	Sim	Sim	Sim
5	Quota sócio efectivo	Sim	Sim	Sim	Sim
6	Filme mais premiado	Parcial	Parcial	Parcial+	Parcial
7	Realizadores com mais filmes	Não	Não	Não	Não
8	Prazo acidente no set	Sim	Sim	Sim	Sim
9	Salário Margarida (armadilha)	Não	Sim	Não	Sim
10	Espectadores Ferro e Sal (armadilha)	Não	Sim	Não	Sim

(Parcial+: chunk relevante apareceu, mas não foi o determinante na resposta)

Explain

Os resultados foram praticamente iguais entre os dois cenários, com uma diferença subtil na pergunta 6.

O que mudou:

Pergunta 6: com chunks de 200, o documento 07-premios-conquistados.md passou a aparecer no top-5 (posição [5]), mostrando a secção de resumo estatístico com o total de 6 prémios. No entanto, o LLM usou predominantemente o chunk [1] do catálogo (que diz “4 prémios no FCP”) e ignorou a informação mais completa. A resposta manteve-se parcial.

Pergunta 7: continuou a falhar. O documento 03-elenco-atores.md foi dividido em 2 chunks, mas o chunk com a tabela de realizadores não foi recuperado para esta pergunta. O embedding dessa secção não é suficientemente próximo da query “realizadores que trabalharam em mais de um filme”.

Porque não existiram mais diferenças: Os documentos do corpus são curtos (~150–250 palavras). Com chunk_size=500, a maioria já cabia num só chunk. Ao reduzir para 200, cada documento passou de 1 para 2 chunks, uma diferença pequena. Em documentos com várias páginas, a redução do chunk size teria um impacto muito maior.

1.5 Failure analysis (Comparação 1)

Onde o sistema falha:

Pergunta 7 (realizadores com mais filmes): falha de retrieval em ambos os cenários da Comparação 1. O chunk com a tabela de realizadores do ficheiro 03-elenco-atores.md nunca foi recuperado para o top-5, independentemente do chunk size usado. O embedding dessa secção não é suficientemente próximo da query.

Pergunta 6 (filme mais premiado): retrieval parcial em ambos os cenários. O sistema recuperou o catálogo (4 prémios no FCP) mas não o histórico com o total correto (6 prémios); com chunks de 200 o doc 07 apareceu no top-5 mas o LLM ignorou-o.

Pergunta 2 (diretora geral): resposta correta mas incompleta. O LLM omitiu "desde 2010" em ambos os cenários, apesar de o chunk correto ter sido recuperado.

Armadilhas (ignorância ou alucinação?): O sistema comportou-se corretamente nas duas armadilhas (perguntas 9 e 10): admitiu ignorância em vez de alucinar, em ambos os cenários da Comparação 1. Este resultado era esperado. As armadilhas testam a geração, não o retrieval, o chunk size não afeta esta dimensão.

Falha mais interessante encontrada: - A falha da pergunta 7 na Comparação 1. Mesmo reduzindo o chunk size de 500 para 200 palavras, o que dividiu o ficheiro 03-elenco-atores.md em 2 chunks, a secção com a tabela de realizadores continuou a não ser recuperada. O problema não é de granularidade dos chunks, mas de distância semântica: o embedding da tabela não é próximo da query "realizadores que trabalharam em mais de um filme", provavelmente porque a tabela contém nomes e números sem contexto verbal suficiente.

O problema é do retrieval ou da geração? Na Comparação 1, a maioria das falhas é do retrieval. Na pergunta 7 o chunk certo nunca entrou no top-5; na pergunta 6 o retrieval trouxe informação incompleta e o LLM usou o chunk errado mesmo quando o correto apareceu (chunks de 200). A pergunta 2 é o único caso de falha clara de geração: o chunk foi recuperado (Sim [4]) mas o LLM não incluiu toda a informação disponível na resposta.

O que mudaria com mais tempo: Para a pergunta 7, aumentaria o top-k de 5 para 10 ou 15, o que aumenta a probabilidade de o chunk com a tabela de realizadores entrar no contexto. Para a pergunta 6, experimentaria um modelo de embedding diferente (ex: mxbai-embed-large em vez de nomic-embed-text), que pode capturar melhor a relação semântica entre "total de prêmios" e o documento de histórico. Para a pergunta 2, refinaria o prompt para instruir o modelo a incluir toda a informação disponível nos chunks, não apenas a resposta principal.

Nota: técnicas abordadas em aulas seguintes (ex: reranking, hybrid search) poderiam resolver os problemas das perguntas 7 e 6 de forma mais robusta.