

Aula 05 — O LLM é Só Uma Peça

SGAIM 2025/2026 — Semana 5

Contexto

Nas semanas 1–4 construíram um GPT do zero: distribuições, autograd, self-attention, treino, geração. Hoje usam o mesmo motor à escala real — e descobrem o que ele **não** consegue fazer sozinho.

Esta aula é de exploração: sem código para implementar, sem testes automáticos. O objectivo é observar, formular hipóteses e discutir.

Pré-requisito

Ollama a correr localmente com pelo menos dois modelos:

```
ollama pull llama3.2:1b
ollama pull llama3.2:3b # ou qwen2.5:7b se tiverem RAM suficiente
```

Se não tiverem Ollama funcional, trabalhem em par com um colega.

Parte 1 — Escala e quantização

Trabalho em pares. Anotem o que observam — vão partilhar com a turma.

Desafio 1 — Comparar modelos

Façam a mesma pergunta aos dois modelos (1B e 7B). Usem perguntas variadas: uma factual, uma de raciocínio, uma criativa.

```
ollama run llama3.2:1b
ollama run qwen2.5:7b
```

O que registar: Em que tipos de perguntas a diferença é maior? Há alguma tarefa onde o modelo pequeno surpreende?

Desafio 2 — Raciocínio multi-passo

Testem problemas que exigem encadear múltiplos passos:

- "Se a Maria é mais alta que o João e o João é mais alto que o Pedro, quem é o mais baixo?"
- "Um comboio parte do Porto às 8h a 100 km/h. Outro parte de Lisboa às 9h a 150 km/h. A que horas se cruzam?"

Comparem 1B e 7B na mesma pergunta.

O que registar: O modelo chega à resposta certa? Onde falha? O erro é de raciocínio ou de aritmética?

Desafio 3 — Geração autoregressiva

Observem a geração enquanto acontece — especialmente num modelo mais lento (7B) ou com uma resposta longa.

Pergunta para discussão: O modelo gera os tokens um a um — porquê? Não podia gerar tudo de uma vez? Liguem a resposta ao que implementaram no ex6.

Desafio 4 — Código

Peçam ao modelo para escrever uma função simples em Python (ex: ordenação, parsing, manipulação de strings). Testem com 1B e 7B.

O que registar: O código corre sem erros? Para que nível de complexidade é que começa a falhar?

Parte 2 — Prompt engineering

Continuação em pares. Experimentem, observem, tentem quebrar.

Desafio 5 — Zero-shot vs few-shot

Tarefa: classificar frases por tema (Desporto / Política / Tecnologia).

Zero-shot — enviem apenas a frase:

```
Classifica o tema desta frase: "A Apple lançou o iPhone 17."
```

Few-shot — adicionem exemplos antes da pergunta:

```
Classifica o tema de cada frase.  
  
"O Benfica goleou o Sporting." → DESPORTO  
"O governo aprovou o orçamento." → POLÍTICA  
"A Apple lançou o iPhone 17." → TECNOLOGIA  
  
"O ciclista venceu o Tour de France." →
```

Testem com frases ambíguas ou que cruzem temas.

O que registar: O formato da resposta muda com os exemplos? E a precisão? Os exemplos alteraram os pesos do modelo?

Desafio 6 — Chain-of-thought

Comparem a resposta directa com a resposta quando pedem ao modelo para "pensar passo a passo":

- Versão directa: "Quanto é 17×24 ?"
- Versão CoT: "Quanto é 17×24 ? Pensa passo a passo."

Experimentem também com um problema de lógica ou texto (não só aritmética).

O que registar: CoT melhora sempre? Há casos onde piora ou prolonga desnecessariamente?

Desafio 7 — System prompt

No Ollama interactivo, definam um system prompt antes de conversar:

```
ollama run llama3.2:3b
>>> /set system "Responde sempre em rimas."
>>> Explica o que é machine learning.
```

Experimentem system prompts diferentes. Depois tentem **quebrar** o system prompt — convencer o modelo a ignorá-lo com a instrução certa.

O que registrar: O modelo mantém a persona? Conseguiram quebrá-la? O que isso implica sobre a segurança de system prompts?

Desafio 8 — Hallucination

Peçam ao modelo informação sobre coisas que não existem:

- "Quem escreveu o livro 'A Sombra do Vento Azul'?"
- "Explica o Teorema de Bergstrom-Kalinski."
- "Qual foi o resultado do jogo da Liga dos Campeões de ontem?"

O que registrar: O modelo inventa com confiança? Admite que não sabe? A hallucination é um bug ou uma consequência do funcionamento do modelo?

Para terminar

No final da aula vamos partilhar as descobertas. Estejam preparados para responder:

- Qual foi o resultado mais surpreendente?
- Encontraram um caso onde o modelo falhou de forma interessante?
- Conseguiram quebrar algum system prompt? Como?